

LLM真的能“读懂”振动信号吗？ PHM-GPT先把波形翻译成文本，再用456,944条指令统一检测、诊断和维修

原创 小蓝 深蓝智析 2026年9月11日 08:06 江苏 1人

PHM-GPT: A Large Language Model for Prognostics and Health Management · Engineering 2025 | 3-1-1 论文解读

论文： PHM-GPT: A Large Language Model for Prognostics and Health Management

作者： Jiaxin Ren, Xue Liu, Tianlei Wang, Zhibin Zhao, Xuefeng Chen, Weihua Li, Ruqiang Yan

期刊： Engineering; DOI: 10.1016/j.eng.2025.11.001; Accepted 5 Nov 2025



打开就能布局，晚一步只能守边境



奔奔王国-塔防策略手游

打开游戏

一句话看懂：PHM-GPT并不是把原始振动波形直接tokenize给LLM。它先用Signal-to-Text (S2T) 把振动转换成统计特征、轴承特征频率和齿轮诊断指标的文本，再通过“PHM知识预训练 → 456k指令微调 → 下游少样本适配”把通用LLM改造成一个能够统一完成异常检测、故障诊断、维护建议和多轮PHM对话的领域模型。

01 | 3分钟速览：这篇真正改的不是“诊断网络”，而是PHM的人机接口

传统PHM通常把异常检测、故障诊断和维护决策拆成三套系统：前两步由信号模型完成，最后再由工程师查手册、看历史记录、制定维修方案。PHM-GPT试图把这三步统一到同一个自然语言模型里。

但它并没有证明LLM可以直接从原始高频振动中自动发现一切。相反，论文采用了非常传统、也非常工程化的前端：先把波形压缩成少量具有机械意义的统计指标，再把这些

指标写进instruction，让LLM负责跨数据集分类、对话、维护生成和解释。

因此，它更像一个“经典信号处理 + 领域知识 + LLM”的混合PHM系统，而不是端到端Raw-signal Foundation Model。

整篇最值得抓住的一句话：PHM-GPT不是让LLM学会听振动，而是先把振动翻译成LLM听得懂的机械语言。

02 | 文章亮点：四件事把“故障分类器”推成了“PHM大模型”

亮点1：S2T把不同采样率、长度和量纲的工业信号统一成文本特征

论文设计24个基础特征，包括12个时域和12个频域指标，再根据不同部件加入轴承和齿轮专用特征。这样不同数据集不再直接比较原始波形长度，而是进入统一的文本接口。

亮点2：InstPHM-456k不是单一诊断集，而是“一条信号生成四种指令”

15个公开数据源共得到114,236个振动实例，每个实例分别构造Detection、Diagnosis、Maintenance和PHM Dialogue四类instruction，因此总数为456,944。


亮点3：训练不是一次LoRA⁹，而是“知识 → 任务 → 场景”三阶段

第一阶段将论文、书籍和维护手册中的PHM知识注入通用LLM；第二阶段使用InstPHM-456k做PHM-specific instruction tuning；第三阶段面对新设备、新工况或私有数据，只做downstream fine-tuning。

亮点4：论文不只测试分类精度，还尝试让模型做归因、阈值和指标发现

这部分很有想象力，但也是最需要降温的部分：归因推理目前只有34.7%的micro precision；阈值只展示10个内圈故障样本；所谓knowledge discovery提出的新BI也只有单轴承案例，作者自己承认尚无经验验证。

03 | 1张核心图精讲：Fig.7其实在回答“通用LLM怎么变成工业PHM模型”



原论文 Fig.7: PHM-GPT三阶段训练框架

图源: Ren et al., Engineering.

Stage 1: Knowledge-centric Injection Pre-training

输入的是PHM领域文本知识：学术论文、专业书籍、维护手册等。目标不是先学某个CWRU^Q故障类别，而是把“阶次分析是什么、轴承故障有哪些典型频率、维修流程怎么组织”等知识注入通用LLM。

Stage 2: PHM-specific Instruction Tuning

再用InstPHM-456k把领域LLM变成真正会执行PHM任务的PHM-GPT。四类任务共享同一套decoder-only模型，而不是为检测、诊断和维修分别训练三个网络。

Stage 3: Downstream Application Fine-tuning

当模型面对新的航空、轨道交通或能源场景时，不重新做前两阶段，只利用少量目标数据继续fine-tune。论文用直升机主减速器私有数据做了1-shot、5-shot和10-shot验证。

这张图最值得记忆的不是LoRA，而是知识层级：先学“PHM是什么”，再学“PHM任务怎么做”，最后学“这台具体设备长什么样”。

04 | S2T: PHM-GPT的真正“传感器接口”其实仍然是经典信号处理

论文共提取24个basic features，其中包含mean、standard deviation、RMS、skewness、kurtosis、crest factor、clearance factor、shape factor、impulse factor等时域统计量，以及相应频域特征。

对轴承，还加入BPFO、BPFI、BSF、FTF等特征频率处的包络谱^Q幅值；对齿轮，则加入FM0、FM4、M6A、NA4等经典旋转机械诊断指标。

这意味着LLM并没有直接学习“原始波形 → 故障”。真正进入语言模型的是一串已经被工程知识压缩后的数值与说明。

Raw vibration→Signal processing / feature extraction→Text instruction→LLM

从工业部署角度，这种方式有两个优势：输入长度很短，而且物理含义明确；但代价也很明显——如果某类故障信息不在这组人工特征中，LLM看不到原始波形，就很难自己发现被S2T丢掉的时频结构。

所以这篇不是“LLM替代信号处理”，反而证明：至少在当前PHM-GPT里，经典信号处理是LLM发挥作用的前提。

05 | 消融最能说明问题：去掉S2T，90.11%直接掉到21.98%

输入设置	Accuracy	Recall	Precision	F1
w/o S2T	21.98	13.80	16.53	12.48
w/o Domain Description	55.43	57.41	55.39	48.51
w/o Task Instruction	61.56	61.78	63.71	58.14
6 features	59.81	58.04	62.86	56.32
12 features	70.40	68.65	70.76	67.64
18 features	84.41	83.69	84.67	83.65


输入设置	Accuracy	Recall	Precision	F1
24 basic features	86.87	85.91	86.07	85.93
All basic + unique features	90.11	87.84	87.71	87.75

这张Table 7其实比网络结构图更重要。没有S2T时，Accuracy只有21.98%，相比完整模型90.11%下降68.13个百分点。

而且特征数量从6→12→18→24 basic→all持续提升，说明PHM-GPT并不是“一个LLM就把任务做了”，而是非常依赖人为设计的机械状态描述。

这也提示了未来路线：如果要真正走向raw-signal multimodal LLM，需要验证模型能否在不依赖如此强手工特征的情况下保持同等泛化。

06 | InstPHM-456k：456k不是456k条独立波形，而是114,236实例×4类任务



原论文 Fig.4：InstPHM-456k的15个数据源分布


图源：Ren et al.。10套轴承数据 + 5套齿轮数据，共114,236个振动实例。

15个数据源包括CWRU、DIRG、HIT^Q、HUB、IMS、JNU、PU、SDUB、SEUB、XJTU等轴承数据，以及UOC、SEUG、SDUG、HUG、BJTU等齿轮数据。

每个振动实例被复用为四类instruction：Detection、Diagnosis、Maintenance、PHM Dialogue，因此：

$$114,236 \times 4 = 456,944 \text{ instructions}$$

这个数字很重要，因为它说明InstPHM-456k的“规模”主要来自多任务展开，而不是456,944段彼此独立的原始监测信号。



原论文 Fig.5：InstPHM-456k构建流程

图源：Ren et al.。监测数据经cleaning、sliding window、S2T；维护文本则来自日志/手册及LLM生成数据，并要求专家验证。

论文还提出可由GPT等LLM生成维护场景与维护流程，再经过专家验证。但附件没有进一步给出InstPHM-456k中“真实维护文本”和“LLM合成维护文本”的具体占比，也没有报告专家一致性统计。

07 | Instruction设计：高准确率的一部分来自“把输出空间主动缩小”

Detection任务只要求回答是否异常；Diagnosis只要求给出故障类型。论文明确指出，这种limited response scope是为了降低hallucination、提高性能。

因此表4和表5中的高Accuracy，本质上更接近“LLM以文本形式执行分类任务”，而不是自由开放式故障分析。

真正开放生成发生在Maintenance和PHM Dialogue中，这也是为什么维护能力主要用对话案例来展示，而不是和检测/诊断一样用一个统一准确率评价。

需要区分两类能力：检测/诊断是受限输出的语言分类；维护/对话才是开放式生成。把两者都笼统叫“LLM推理”容易夸大。

08 | LoRA架构：论文把低秩适配放进Attention和FFN，但“大模型”不是创新核心

$$W_{finetuned} = W_{pretrained} + B A, rank(A, B) = r \ll d$$

论文在decoder-only LLM中保持预训练权重冻结，通过LoRA学习低秩更新；模型结构部分同时描述了Group Attention与FFN中的LoRA，实验设置中LoRA rank=8、dropout=0.1、cutoff length=2048。


训练使用AdamW，初始学习率 10^{-4} ，最多50 epochs。不同backbone包括Phi-1.5、Qwen-2.5、LLaMA-3和DeepSeek-R1。

但从消融看，模型架构的收益很难与S2T、instruction和数据规模分开。PHM-GPT的独特性更应该归在“领域表示 + 多任务指令 + 三阶段适配”，而不是LoRA本身。

09 | 异常检测：总Accuracy 96.92%，领先最强时序基线3.55个百分点

模型	Total Accuracy
FEDformer	92.49%
PatchTST	92.47%
TimesNet	93.37%
PHM-GPT	96.92%

PHM-GPT的总检测Accuracy为96.92%，相比TimesNet的93.37%高3.55个百分点，相对提升约3.8%。HIT、CWRU、XJTU等数据集接近100%。



原论文 Fig.9: 不同模型在15个数据集上的检测Accuracy雷达图


图源：Ren et al.。PHM-GPT的雷达图整体更均衡。

不过论文把数据的长尾不均衡完整保留下来，而主结果表主要展示Accuracy，没有给15套数据统一的macro-F1或各类别召回。因此“长尾鲁棒性”有一定证据，但还不能只靠总Accuracy完全证明。

10 | 故障诊断：90.11%是总平均第一，但很多单数据集并不是第一

模型	Total Accuracy
Crossformer	86.64%
FEDformer	86.42%
TimesNet	87.19%
PatchTST	88.64%
PHM-GPT	90.11%

PHM-GPT总诊断Accuracy=90.11%，相比最强基线PatchTST的88.64%提升1.47个百分点。它在XJTU达到100%，并在SEUB、HUG等难数据上表现突出。



原论文 Fig.10: 不同模型在15个数据集上的诊断Accuracy雷达图

图源：Ren et al.。

但单数据集上，Reformer、Crossformer、TimesNet等模型经常达到99%-100%。PHM-GPT的优势主要是跨15个数据源后的总体均衡性，而不是每一个实验台数据集都比专用模型更高。

11 | Few-shot直升机主减速器：5-shot、10-shot最好，但1-shot Accuracy不是第一



原论文 Fig.8: 1:1直升机主减速器故障模拟试验台

图源：Ren et al.。私有数据与公开训练集隔离，采样频率10,240 Hz。

Setting	TimesNet Accuracy	PHM-GPT Accuracy	PHM-GPT F1
1-shot	32.91%	32.00%	32.40%
5-shot	61.84%	64.00%	61.35%
10-shot	68.13%	70.44%	69.51%

私有数据包含healthy、ball spalling、inner race spalling、outer race spalling和cage cracking五类。PHM-GPT在5-shot和10-shot的Accuracy最高，说明少样本适配确实有效。


但1-shot Accuracy=32.00%，略低于TimesNet的32.91%；5-shot的F1=61.35也略低于TimesNet 61.40。

所以“few-shot全面领先”不准确。更稳妥是：随着标注从1-shot增加到5/10-shot，PHM-GPT的优势开始明显建立。

12 | 维护决策：最像“大模型”的部分，反而主要是定性比较

Fig.12比较Baichuan-2、Phi-3、LLaMA-3、Qwen-2.5和PHM-GPT对“轴承内圈故障如何维护”的回答。PHM-GPT给出的建议更具体，例如当内圈损伤显著时建议更换轴承，并考虑工作条件选择替代件。

但这一部分没有像诊断任务一样给出专家打分、可执行性评分、错误建议率或真实维修闭环成功率。因此“maintenance performance superior”目前主要是案例层面的定性证据。



原论文 Fig.13: PHM-GPT把检测→诊断→维护串成多轮对话

图源: Ren et al.。

多轮对话的价值非常明确: 它把传统PHM中分散的模型输出转换成工人可以直接交互的接口。但在安全关键设备中, 这种维护建议仍需要规则、手册或专家进行最终约束。



腾讯WorkBuddy
帮你做完工作

文档表格PPT、方案图表
一句需求快速交付

立即体验



WorkBuddy AI办公助手, 免部署安装即用

WorkBuddy

查看


13 | 所谓“涌现能力”: 论文自己给出的数据, 其实是在主动降温

13.1 Attribution Reasoning: 有解释, 但目前远未成熟

论文选50个测试案例, 把模型生成的root causes与专家标注做多标签比较: micro-averaged precision只有34.7%, 同时diagnostic accuracy只有24.0%。作者明确写道 reasoning ability is not yet fully mature。

所以这部分最不应该宣传成“LLM已经解决PHM可解释性”。更准确是: 模型开始能生成类似工程解释的语言, 但解释与专家因果判断的一致性目前很低。

13.2 Threshold Setting: 看起来合理，但验证只有10个同类故障样本




原论文 Fig.14: PHM-GPT给出的P2P、RMS、CF、CLF、IF阈值与10个内圈故障样本

图源: Ren et al.。

模型能给出Peak-to-Peak、RMS、Crest Factor、Clearance Factor和Impulse Factor的“normal range”，并在10个inner-race fault样本上展示部分特征落在正常区间之外。

但这不是系统性的threshold calibration实验：没有跨设备、跨转速、跨健康状态验证，也没有和统计阈值、专家阈值比较误报率/漏报率。当前更适合看作可解释性案例。

13.3 Knowledge Discovery: BI更像“候选健康指标”，不是已经发现的新知识



原论文 Fig.15: PHM-GPT提出的Bearing Index在XJTU-SY Bearing 2-1上的变化

图源: Ren et al.。

$$BI = (\text{Root Amplitude} / \text{RMS}) \times (1 - \text{Kurtosis} / 3)$$

模型自己提出BI，并在XJTU-SY Bearing 2-1上显示故障起始附近明显上升。这个结果确实很有启发，但论文同时明确承认：BI lacks empirical verification，而且趋势并不强单调。

因此公众号里更准确的说法应该是“LLM提出了一个可供后续验证的候选健康指标”，而不是“LLM发现了新的轴承退化规律”。

14 | 一个容易被标题掩盖的事实：当前PHM-GPT并没有做RUL预测

论文标题使用Prognostics and Health Management，但实际统一验证的任务是Anomaly Detection、Fault Diagnosis、Maintenance Decision-making 和 PHM Dialogue。

RUL prediction在Introduction中被列为PHM重要任务，但在Conclusions里被明确列为未来扩展方向。

所以当前PHM-GPT更准确是“Health Management + Diagnostic Decision LLM”，尚未覆盖PHM里最典型的prognostics/RUL部分。

15 | 计算成本：从毫秒级信号模型，走到了13秒级甚至21秒级LLM

Backbone	Params	GPU Memory	Train (3 epochs)	Inference / sample
Phi-1.5	1.3B	3 GB	4 h	6.7 s
Qwen-2.5	7B	16 GB	21 h	12.9 s
LLaMA-3	8B	17 GB	25 h	13.4 s
DeepSeek-R1	14B	34 GB	49 h	21.3 s

更大 backbone 确实带来更高 Accuracy：Phi-1.5 约 85.13%，LLaMA-3 90.11%，DeepSeek-R1 91.59%。但代价是推理时间从6.7秒增加到21.3秒。

传统PHM分类器通常毫秒级响应，因此这篇更适合“解释、诊断复核和维护决策交互”，而不是直接替代保护系统里的高速在线报警链路。

论文自己也把pruning、quantization和knowledge distillation列为未来部署方向。

16 | 1段代码：最小复现“Signal-to-Text → Instruction → LoRA PHM-GPT”

下面是教学版PyTorch/伪代码，不是作者官方实现。它故意保留经典信号处理前端，因为这正是论文最关键的设计。

```
import numpy as np

def signal_to_text(x, fs, rpm, component, meta):
    feat = {}
    feat["mean"] = x.mean()
    feat["std"] = x.std()
    feat["rms"] = np.sqrt(np.mean(x**2))
    feat["skewness"] = skew(x)
    feat["kurtosis"] = kurtosis(x)
    feat["crest_factor"] = np.max(np.abs(x)) / (feat["rms"] + 1e-8)
    feat.update(frequency_domain_features(x, fs)) # 12 freq features

    if component == "bearing":
        # amplitudes around BPFO / BPFI / BSF / FTF after envelope analysis
        feat.update(bearing_characteristic_features(x, fs, rpm, meta))
    elif component == "gear":
        # FM0 / FM4 / M6A / NA4 ...
        feat.update(gear_diagnostic_features(x, fs, rpm, meta))

    return format_as_phm_text(feat, fs=fs, rpm=rpm, component=component)

prompt = f"""
System: You are a PHM expert.
Task: Diagnose the fault type.
Equipment: bearing
Monitoring indicators:
{signal_to_text(x, fs, rpm, "bearing", bearing_meta)}
Output only one fault label.
"""

# Domain LLM + LoRA:
# W_finetuned = W_pretrained + B @ A, rank(A,B) << model width
output = phm_gpt.generate(prompt, max_new_tokens=32)
```

17 | 这篇到底算不算“物理 + 数据”？——不是PINN，而是“机械机理特征 + 领域知识 + LLM”

这篇没有把动力学微分方程或物理残差写入LLM loss，所以不属于PINN。

但S2T并非纯统计黑箱：轴承BPFO/BPFI/BSF/FTF来自滚动轴承运动学，齿轮FM0/FM4/M6A/NA4来自经典齿轮振动诊断知识；维护手册和PHM文献又提供显式领域知识。

因此它很适合放进“物理 + 数据”的另一条路线：不是让物理方程直接约束神经网络，而是先用机械诊断机理把原始信号组织成具有物理意义的语言特征，再交给LLM做跨任务推理。

更准确的标签：Mechanism-guided Signal Representation + Domain Knowledge Injection + Instruction-tuned LLM。物理/机理负责“怎么描述信号”，大模型负责“怎么理解、统一任务和生成决策”。

18 | 这篇论文还需要谨慎看待哪些边界？

第一，PHM-GPT不直接处理raw vibration；其效果高度依赖S2T手工特征。去掉S2T后Accuracy只有21.98%，说明当前LLM能力不能脱离信号处理前端单独讨论。

第二，InstPHM-456k的456,944条instruction来自114,236个实例×4类任务，不能理解为45.7万段独立监测信号。

第三，数据覆盖轴承和齿轮两类旋转机械部件，尚不能直接外推到泵、压缩机、电机、阀门、液压系统或复杂整机。

第四，当前任务不包含RUL prediction；论文自己把RUL列为未来工作，因此“完整PHM大模型”仍在路上。

第五，维护决策主要用案例比较，没有独立专家评分、错误建议率或真实维修效果指标。

第六，归因推理只在50个案例上达到34.7% precision和24.0% diagnostic accuracy，当前解释能力明显不足以支持安全关键决策。

第七，threshold setting只展示10个同类inner-race fault样本；knowledge discovery的BI仅在XJTU-SY Bearing 2-1上展示，并且论文明确承认缺乏经验验证和单调性。

第八，论文保留数据源、故障类别和转速的自然长尾分布，但主跨数据集结果主要报告Accuracy；缺少统一macro-F1、per-class recall等更适合不均衡场景的指标。

第九，监测信号预处理中使用sliding window，而正文只说114,236 instances按8:2划分，没有说明是否按原始试验run/采集文件进行group split。如果相邻重叠窗口被随机分到训练和测试，可能产生信息泄漏；附件没有足够信息确认这一点，复现时需要重点检查。

第十，论文提出维护数据可以由GPT等生成并由专家验证，但没有给出合成维护文本占比、验证人数和一致性统计，维护instruction的真实性边界不够透明。

第十一，Stage 1知识预训练使用论文、书籍和维护手册，但正文没有给出语料规模、token数量和数据清洗细节，难以独立复现“knowledge injection”具体贡献。

第十二，Table 8标题写成maintenance task，但上下文讨论的是LLM backbone对PHM-GPT性能的影响，且LLaMA-3的90.11与诊断总Accuracy完全一致，存在表题/任务口径需要进一步核对的地方。

第十三，大模型推理6.7-21.3秒/样本，不适合直接替代毫秒级保护与报警链路；更现实的角色是诊断复核、解释和维护决策。

结语 | 这篇真正证明的，不是“GPT会听振动”，而是“信号处理可以成为LLM的工业语言层”

PHM-GPT最有价值的地方，是把过去互相割裂的三块能力放到了同一个接口：振动信号经过S2T变成可读的机械状态描述，领域预训练补充PHM知识，instruction tuning让模型统一执行检测、诊断、维护和对话。

但消融也非常诚实地告诉我们：当前系统的工业智能仍然建立在经典信号处理之上。没有这些特征，LLM并不会自动从原始波形中恢复同等诊断能力。

因此这篇更像一个过渡型范式：先把工业时序“语言化”，再借用LLM的知识、上下文和生成能力，逐步走向真正能处理raw signal、多模态监测和RUL预测的PHM Foundation Model。

Signal Processing Knowledge → Textualized Health State → Domain LLM
→ Detection / Diagnosis / Maintenance: 这篇真正搭起的是“工业信号世界”与
“语言模型世界”之间的一座桥。

工业脉搏 · 目录 ≡

< 上一篇

别把振动信号硬翻译成文字：VLT如何用“时序 + 频谱视觉 + 知识”做工业多模态基础模型

下一篇 >

每一步都像专业答案，为什么连起来却可能危险？SC-MDG 用工程约束校核故障诊断路径

阅读 1091 修改于2026年9月11日



就三天！征集38套房子，23800起装好三房两厅，不限户型！😱



索菲亚家居全屋定制

领取优惠

留言 1

写留言  



脚踏实地埋头... 🍷 浙江 9月14日

👍 1

这个行业内，牛逼的都不发论文，直接开公司，只要你的真技术，直接开公司才能获利，论文有个毛用啊

